

Modelos predictivos para estimar la densidad de nitrógeno en cultivos de frutas a partir de imágenes multispectrales y plataformas de IoT: una revisión sistemática de la literatura.

1th Jorge Enrique Chaparro Mesa
Estudiantes de doctorado en
Ingeniería Electrónica
Universidad de Antioquia,
Ciudad, Medellín
jorge.chaparro1@udea.edu.co

2th José Edinson Aedo Cobo
Docente Investigador
Universidad de Antioquia,
Ciudad, Medellín
jose.aedo@udea.edu.co

Abstract— Traditional agriculture is highly vulnerable to climate change and the presence of diseases and pests. It is defined mainly by the use of dietary techniques, which minimize the productive capacity of soils and cause negative impacts on the environment and human health. One of the most polluting elements of the environment and also one of the macronutrients most demanded by crops is Nitrogen (N), which has a direct relationship with the growth, weight and quality of the fruit, therefore it requires an adequate and controlled supply to maintain optimal crop performance, without causing harmful effects on the environment. There are several techniques to make the diagnosis, which can be classified into destructive and non-destructive. This systematic literature review is focused on the use of non-destructive methods such as multispectral images and sensors integrated in the field, which allow estimating the nitrogen density in a timely manner and provide additional agrometeorological information, which allows a more comprehensive management of the crop. In this sense, the Internet of Things (IoT) provides essential tools to carry out the monitoring and follow-up of agricultural processes, thanks to the interoperability of communication systems, and the use of sensors in the soil and plant, that detect and monitor variables in real time. On the other hand, multispectral photogrammetry allows to perform vegetation indices which provide information on the vegetative state of the crop, plant transpiration and biomass, among other parameters. These instruments, together with predictive models, which allow us to understand the complexity that characterizes agroecological and environmental systems, can become powerful interdisciplinary tools for the development of research and decision-making processes, thanks to the fact that they allow analysis of the agroecological systems.

Keywords— *Multispectral imaging, Unmanned aerial vehicle (UAV), Internet of things IoT, Predictive Models, Sensors in the crop, pineapple cultivation.*

I. INTRODUCCIÓN

En este estudio, se realizó una revisión sistemática de la literatura (SLR) para extraer y sintetizar información de trabajos relacionados con imágenes multispectrales y tecnologías IoT

aplicadas en modelos predictivos para estimar el contenido de nitrógeno en diferentes cultivos.

El estudio sigue un diseño de investigación de revisión sistemática para sintetizar y presentar un análisis integral y estructurado de la literatura en el ámbito de la “Agricultura Inteligente”. Por lo tanto, la investigación se basa en la metodología de revisión sistemática de la literatura (SLR) propuesta por Tranfield [1]. Las revisiones basadas en evidencia propuestas por Tranfield [1], es una metodología empleada con éxito para una forma integral sistemática y el estado de la técnica de revisión de la literatura en diferentes campos.

Sobre la base del criterio de búsqueda establecido, se recuperaron 320 estudios relevantes de cinco bases de datos electrónicas, de los cuales se seleccionaron 50 estudios para su posterior análisis utilizando criterios de inclusión y exclusión. Estos documentos fueron seleccionados cuidadosamente y organizados por temáticas en mendeley. Según el análisis, las variables más utilizadas para la elaboración de los modelos son la temperatura ambiente, humedad del suelo, las precipitaciones y el tipo de suelo, y el algoritmo más aplicado en estos modelos son las redes neuronales artificiales. Según este análisis adicional, *Convolutional Neural Networks (CNN)* es el algoritmo de aprendizaje profundo más utilizado en estos estudios, y los otros algoritmos de aprendizaje profundo ampliamente utilizados son memoria a largo plazo (LSTM) y redes neuronales profundas (DNN).

Por otra parte se realizó un análisis sobre los cultivos en los cuales se viene aplicando estas técnicas de diagnóstico de nitrógeno a través del uso de imágenes multispectrales con el apoyo de sensores en el suelo y la planta.

Así mismo se pudo evidenciar que los modelos predictivos son una herramienta de apoyo a la toma de decisiones para la predicción del rendimiento de los cultivos, incluyendo el apoyo para la toma de decisiones sobre cuando y que contenido de Nitrógeno aplicar, al igual que las fechas y cantidades de agua que requiere el cultivo, estas decisiones normalmente son

utilizadas para desarrollar procesos de fertirriego, así mismo estos modelos aportan en las decisiones sobre las mejores temporadas para recoger la cosecha.

II. TRABAJOS RELACIONADOS

La predicción del rendimiento de los cultivos es una tarea esencial para los responsables de la toma de decisiones. Un modelo preciso de predicción del rendimiento de los cultivos puede ayudar a los agricultores a decidir sobre cuándo y que cantidad de nutrientes o de agua aplicar al cultivo. Este artículo de revisión ha investigado lo que se ha hecho sobre el uso del aprendizaje automático en la predicción del rendimiento de los cultivos especialmente en la estimación de nitrógeno a través de dispositivos multispectrales y sensores en suelo y planta.

Van Klompenburg realizaron una revisión sistemática de literatura referente al aprendizaje automático como una importante herramienta de apoyo a la toma de decisiones para la predicción del rendimiento de los cultivos. Los autores concluyen que las publicaciones revisadas utilizan una variedad de características, dependiendo del alcance de la investigación y la disponibilidad de datos. Cada artículo investiga la predicción de rendimiento con aprendizaje automático, pero difiere de las características. Los estudios también difieren en escala, posición geológica y cultivo [2].

Spanaki, realizaron un trabajo sobre AgriTech, la cual se basa principalmente en la conceptualización y la conciencia sobre el contexto AgriTech impulsado por la inteligencia artificial relevante para las operaciones agrícolas para una agricultura inteligente, eficiente y sostenible. El estudio proporciona una referencia normativa única para la definición, el contexto y las direcciones futuras del campo para futuras investigaciones hacia el contexto operativo de AgriTech [3]. *Chlingaryan y Sukkarieh* realizaron un estudio de revisión sobre la estimación del estado del nitrógeno utilizando el aprendizaje automático [4]. El documento concluye que la rápida evolución de las técnicas de detección de tecnología dará lugar a soluciones rentables en el sector agrícola.

Boursianis, realizaron un trabajo de revisión sobre Internet de las cosas (IoT) y los vehículos aéreos no tripulados (UAV). En este artículo realizaron una revisión de las últimas investigaciones sobre tecnología IoT y UAV aplicadas en agricultura. Describieron los principios fundamentales de la tecnología de IoT, incluidos los sensores inteligentes, los tipos de sensores de IoT, las redes y los protocolos utilizados en la agricultura, así como las aplicaciones y soluciones de IoT en la agricultura inteligente [5]. *Li, Lecourt y bishop* realizaron un estudio de revisión sobre la determinación de la madurez de los frutos para decidir el tiempo óptimo de cosecha y la predicción de rendimiento [6]. *Beulah* realizó un estudio sobre las diversas técnicas de minería de datos que se utilizan para la predicción del rendimiento de los cultivos y concluyó que la predicción del rendimiento de los cultivos podría resolverse mediante el empleo de técnicas de minería de datos [7].

Por otra parte realizaron una revisión de las aplicaciones de la teledetección en la agricultura para la seguridad alimentaria, teniendo en cuenta el crecimiento y el rendimiento de cultivos, riego y pérdidas de cultivos [8].

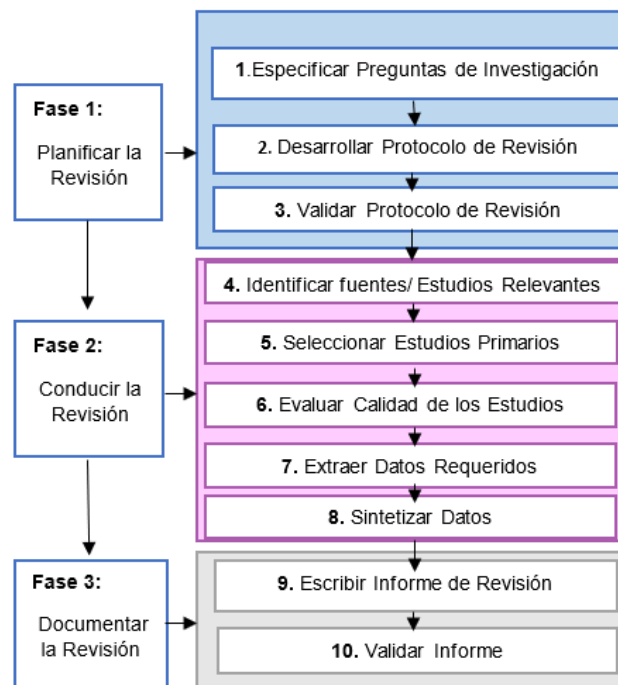
III. METODOLOGÍA.

A. Protocolo de Revisión.

En primer lugar, se definen las preguntas de investigación. Cuando las preguntas de investigación están listas, se utilizan bases de datos para seleccionar los estudios relevantes. Las bases de datos que se utilizaron en este estudio son Science Direct, Scopus, Web of Science, Springer y Google Scholar.

- **Fase 1.** La primera etapa consiste en planificar la revisión. En esta etapa, se identifican las preguntas de investigación, se desarrolla un protocolo y finalmente, se valida el protocolo para ver si el enfoque es factible. Además de las preguntas de investigación, también se definen los lugares de publicación, las cadenas de búsqueda inicial y los criterios de selección de la publicación.
- **Fase 2.** La segunda etapa es la realización de la revisión. Al realizar la revisión, las publicaciones se seleccionan pasando por todas las bases de datos. Se extraen los datos, lo que significa que se almacena su información sobre autores, año de publicación, tipo de publicación y más información sobre las preguntas de investigación. Una vez que se extraen correctamente todos los datos, se sintetizan para proporcionar una descripción general de los artículos relevantes publicados hasta el momento.
- **Fase 3.** En la etapa final, también conocida como Informe de la revisión, la revisión concluye con la documentación de los resultados y el tratamiento de las preguntas de investigación.

Fig. 1. Detalles de las fases del protocolo de revisión.



Fuente: Elaboración propia -adaptada de [2]

B. Pregunta de Investigación

¿Es posible a través de modelos predictivos y técnicas no invasivas, estimar la cantidad de nitrógeno que requiere un cultivo de piña, a partir de información suministrada por imágenes multiespectrales y sensores en campo integrados en una plataforma IoT (Internet of Things)?

Esta SLR tiene como objetivo obtener información sobre los estudios que se han publicado en el dominio de los modelos predictivos y técnicas no invasivas para estimar la cantidad de nitrógeno en los cultivos frutales a partir de información suministrada por imágenes multiespectrales y sensores instalados en los cultivos. Para este estudio de SLR, se han definido las siguientes preguntas de investigación (RQ).

1. RQ1- ¿Qué algoritmos de modelos predictivos se han utilizado en la literatura para la estimación de la cantidad de nitrógeno en los cultivos?
2. RQ2: ¿Cuáles son los avances en el procesamiento de imágenes multiespectrales y la modelización para la estimación del nitrógeno en los cultivos frutales?
3. RQ3- ¿Qué parámetros de evaluación y enfoques de evaluación se han utilizado en la literatura para predecir la cantidad de nitrógeno en los cultivos frutales?
4. RQ4- ¿Cómo se integra el internet de las cosas (IoT) y los vehículos aéreos no tripulados (UAV) para la predicción de la cantidad de nitrógeno en los cultivos frutales?
5. RQ5- ¿Cuáles son los desafíos en el campo de la predicción del rendimiento de los cultivos frutales mediante modelos predictivos?
6. RQ6- ¿Cuáles son los avances respecto a métodos no invasivos para estimación de nitrógeno en cultivos de piña?

C. Estrategia de búsqueda.

Las bases de datos que se utilizaran en este estudio son *Science Direct*, *Scopus*, *Web of Science*, *Springer*, y *Google Scholar*. En esta estrategia de búsqueda se aplicarán criterios de exclusión y se procesan todos los resultados, para esto se construye una cadena de búsqueda de la siguiente forma ("Aprendizaje automático" O "modelos predictivos") Y "minería de datos" Y ("predicción de nitrógeno" O "Estimación de nitrógeno" O "predicción de nitrógeno") Y ("Imágenes multiespectrales" O "Imágenes hiperespectrales") Y (IoT para predicción de cultivos).

Se proporciona una descripción específica de las cadenas de búsqueda por base de datos de la siguiente manera:

- **Science direct:** la cadena de búsqueda es ["aprendizaje automático" Y "predicción de rendimiento"] (título, resumen, palabras clave) y

["("aprendizaje automático" O "Modelos predictivos") Y "minería de datos" Y ("predicción de rendimiento") O "pronóstico de rendimiento" O "estimación de rendimiento")"] (título, resumen, palabras clave).

- **Scopus:** la cadena de búsqueda es ["aprendizaje automático" Y "predicción de rendimiento"] (título, resumen, palabras clave) y [("("aprendizaje automático" O "inteligencia artificial") Y "minería de datos" Y ("predicción de rendimiento" O "Pronóstico de rendimiento" O "estimación de rendimiento"))] (título, resumen, palabras clave).
- **Web of Science:** la cadena de búsqueda es ["aprendizaje automático" Y "predicción de rendimiento"] (título, resumen, palabras clave del autor y Keywords Plus).
- **Springer:** la cadena de búsqueda es ["aprendizaje automático" Y "predicción de rendimiento"] (en cualquier lugar) y [("("aprendizaje automático" O "inteligencia artificial") Y "minería de datos" Y ("predicción de rendimiento" O "pronóstico de rendimiento" O "estimación de rendimiento"))] (en cualquier lugar)
- **Google Scholar:** la cadena de búsqueda es ["aprendizaje automático" Y "predicción de rendimiento"] (en cualquier lugar) y [("("aprendizaje automático" O "inteligencia artificial") Y "minería de datos" Y ("predicción de rendimiento" O "pronóstico de rendimiento" O "estimación de rendimiento"))] (en cualquier lugar).

D. Criterios de exclusión.

Para excluir estudios irrelevantes, los estudios se analizaron y calificaron según criterios de exclusión para establecer los límites de la revisión sistemática. Los criterios de exclusión (CE) se muestran a continuación:

- **Criterio de exclusión 1:** la publicación no está relacionada con el sector agrícola y la predicción del rendimiento combinada con el aprendizaje automático
- **Criterio de exclusión 2:** la publicación no está escrita en inglés
- **Criterio de exclusión 3:** publicación duplicada o ya recuperada de otra base de datos
- **Criterio de exclusión 4 -** El texto completo de la publicación no está disponible
- **Criterio de exclusión 5:** la publicación es un artículo de revisión / encuesta
- **Criterio de exclusión 6 -** La publicación se ha publicado antes de 2016

Para responder a las seis preguntas de la investigación, se extraen y sintetizan datos de los estudios seleccionados. La información recuperada se centra en comprobar si los estudios cumplen o no los requisitos establecidos en los criterios de

exclusión y en responder a las preguntas de investigación. Los estudios seleccionados que pasan los criterios de exclusión se seleccionan.

IV. RESULTADOS

A continuación, se lleva a cabo un análisis del estado del arte en el uso de imágenes multiespectrales y sensores en campo en un contexto agrícola. También se revisan investigaciones relacionadas con algunas de las técnicas de modelado aplicadas a la agricultura. Finalmente se analizan trabajos publicados sobre el cultivo de piña, bajo un enfoque de agricultura de precisión.

Imágenes Multiespectrales aplicadas a la agricultura.

Una de las tecnologías emergentes más importantes en la agricultura inteligente son las imágenes multiespectrales, las cuales se han implementado para abordar diversos problemas en la producción agrícola [9]. A continuación, se detallan algunos trabajos realizados en diferentes cultivos. En el cultivo de arroz se han utilizado imágenes multiespectrales de infrarrojo cercano (NIR) para la estimación de biomasa utilizando vehículos aéreos no tripulados (UAV), los autores de este trabajo calcularon 7 índices de vegetación que se combinan en forma de regresión multivariada dependiendo de la etapa de crecimiento de la planta: vegetativo, reproductivo o de maduración [10]. En este mismo sentido se usaron imágenes multiespectrales para el cálculo de índices de vegetación como el NDVI, NDRE, GNDVI y GRVI en cultivos de café de castilla, utilizando la cámara MicaSense RedEdge M, la cual trabaja en las bandas espectrales azul, verde, roja, borde rojo e infrarrojo cercano (NIR) y fue ubicada en un vehículo aéreo no tripulado de referencia, DJI Phantom 4 [11]. En [12] los autores presentan una metodología para predecir el NDVI entrenando un modelo de crecimiento de cultivos con datos históricos. Aunque utilizan un modelo de crecimiento de soja muy simple, la metodología podría extenderse a otros cultivos y modelos más complejos.

Como se mencionó anteriormente el Crop Water Stress Index (CWSI), es un parámetro importante para medir el nivel de estrés hídrico de la planta. En este sentido en [13], se propone un dispositivo óptico multiespectral portátil de bajo costo para evaluar de forma precisa del estado vegetativo de la planta. Así mismo en [14], se realizó un estudio para investigar el uso potencial del índice de estrés hídrico (CWSI), en la programación de riego para plantas de semillas de calabaza irrigadas por goteo. En este estudio se concluyó, basándose en los hallazgos, que CWSI podría usarse de manera confiable en la programación del riego y la estimación del rendimiento de las plantas de semilla de calabaza.

Por otra parte, también se han utilizado las imágenes multiespectrales para determinar nutrientes como el nitrógeno, con este enfoque se pueden destacar el modelo para estimar el nivel de nitrógeno en el maíz a partir de imágenes multiespectrales tomadas con vehículos aéreos no tripulados (UAV); los resultados mostraron que el modelo puede estimar los niveles de nitrógeno con un 80% de precisión, sin embargo

los autores recomiendan para mejora la precisión del modelo la inclusión de otras variables como la clorofila o el pH de la tierra, evaluar más etapas del maíz para poder incrementar la robustez del modelo y/o estimar distintas etapas según la decisión del productor [15]. Otra investigación realizada en cultivos de pepino, demostró que las imágenes multiespectrales pueden usarse muy bien para analizar el contenido de nitrógeno de las hojas, además tienen mayores ventajas sobre los métodos tradicionales los cuales son destructivos y requieren mucho tiempo [16]. En el trabajo realizado por Zhulin Chen, proponen un modelo de estimación del contenido total de nitrógeno (TNC) en hojas de sándalo, el cual toma una estación de muestreo y las condiciones del sitio como variable ficticia y efecto aleatorio, respectivamente. Este estudio demuestra las ventajas de utilizar el modelo no lineal de efectos mixtos con variables ficticias para obtener un modelo de estimación más confiable para el diagnóstico nutricional de especies arbóreas raras. Las imágenes multiespectrales se obtuvieron de las hojas utilizando una cámara de cinco bandas de bajo costo (*RedEdge*, *MicaSense*) [17]. El carbono orgánico del suelo (SOC), también ha sido estimado para calcular índices de vegetación, a partir de imágenes multiespectrales, los cuales se han utilizado como predictores para reflejar el crecimiento de la vegetación y para predecir el (SOC), basado en las relaciones entre el crecimiento vegetativo y la fertilidad del suelo [18]. Otros trabajos se han realizado para predecir el contenido de azúcar de las manzanas "Fuji" a través de imágenes multiespectrales [19].

En el trabajo realizado por Yubin Lan, hacen uso de imágenes multiespectrales para la detección de la enfermedad Citrus Huanglongbing (HLB), también conocido como reverdecimiento de los cítricos [20]. En [21] se investigó el uso de imagen multiespectral para cuantificar la calidad del fruto de la granadilla. Se estudiaron tres factores de calidad, incluidos los sólidos solubles totales (TSS), el pH y la firmeza en cuatro etapas de madurez diferentes, y estos datos se correlacionaron con la información espectral extraída de las imágenes tomadas en cuatro espectros de longitud de onda. De los trabajos anteriormente revisados se puede concluir que para los sistemas agrícolas es fundamental la resolución espacial y temporal, teniendo en cuenta que con esta información se estiman las cantidades de nutrientes, agua y energía. En este sentido las imágenes multiespectrales y satelitales aportan a la agricultura de precisión en diversos escenarios, incluidos el riego, la fertilización, el uso de pesticidas, el manejo de malezas, el monitoreo del crecimiento de las plantas, el manejo de enfermedades de los cultivos y el fenotipado a nivel de campo [22] [23], [24]. En la Tabla 1 se muestra el resumen de las publicaciones analizadas.

Redes de sensores aplicados a la agricultura

En un entorno agrícola, los dispositivos de IoT proporcionan información útil sobre una amplia gama de parámetros físicos para mejorar las prácticas de cultivo. En [25] se desarrolló un sistema de monitoreo para manejar eficientemente los problemas de riego. La solución propuesta se desarrolló mediante el establecimiento de una red de sensores

inalámbricos distribuidos (WSN), los cuales transmitieron los datos a un servidor común. Con estos datos y a través de algoritmos de aprendizaje automático (ML) se realizaron predicciones de patrones de riego basados en escenarios climáticos. Por otra parte en [26], desarrollaron un sistema que emplea una red MCFN (*Multi-Context Fusion Network*), que usa aprendizaje profundo para el reconocimiento práctico de enfermedades en los cultivos. En [27], los autores desarrollaron un sistema de monitoreo basado en sensores para el control de enfermedades epidémicas. Dicho sistema proporciona servicios de monitoreo ambiental del entorno del cultivo y predice de forma temprana las condiciones que conducen al brote de enfermedades epidémicas. Por su parte en [28], se presenta el diseño y la implementación de una red de sensores inalámbricos que monitorean la temperatura del aire, la humedad y la intensidad de la luz ambiental en un cultivo con el fin de medir y controlar diferentes parámetros útiles para el cultivo. El sistema propuesto se implementó en un campo de berenjenas y la viabilidad de la red se probó mediante la evaluación de los resultados en campo. De otra parte en [29], se desarrolló el proyecto AgricULTIC, una plataforma IoT para la adquisición de datos, monitoreo y control de procesos agroindustriales. La plataforma software recibe datos de sensores instalados en campo y genera alertas tempranas vía SMS, llamadas de voz o correo electrónico, permitiendo al agricultor generar acciones y tomar decisiones en tiempo real. Finalmente los autores de [30], proponen un nuevo enfoque en la utilización de la tecnología IoT como un sistema de monitoreo remoto para controlar las condiciones climáticas interiores a través de la manipulación de parámetros de diodos emisores de luz (LED) que incluyen espectros, fotoperiodo e intensidad para aumentar los rendimientos y reducir el tiempo de respuesta. Este estudio mostró que el crecimiento del cultivo de *Brassica chinensis*, conocida como *bok choy*, una variedad de col china, al estar bajo diferentes longitudes de onda de la fuente de luz, ha influido en el rendimiento del crecimiento de las plantas y en las características fitoquímicas. Finalmente se puede concluir que los sistemas de agricultura inteligente basados en Internet de las cosas son de los más prometedores para aumentar la producción de alimentos y reducir el consumo de recursos como el agua. En la Tabla 3, se resumen algunos trabajos con redes de sensores aplicados a la agricultura, especialmente en el monitoreo de variables agrometeorológicas.

Modelos Predictivos aplicados a la agricultura

A continuación, se describen diferentes técnicas que se vienen empleando en la construcción de modelos predictivos aplicados a la agricultura.

■ ***Modelos matemáticos en tiempo continuo y discreto.***

En [31], se desarrolló un modelo que considera la cantidad de agua en el cultivo y su relación con el rendimiento, en este modelo se incluyen variables como, concentración volumétrica

de agua en el suelo, límite inferior para la absorción de agua de la planta, límite superior de drenado de la concentración de agua en el suelo y agua almacenada en un día. En [32], presentan un modelo matemático no lineal para evaluar elementos del suelo como carbono, nitrógeno y sodio, en un cultivo de frijol; en este trabajo se realizaron correlaciones entre nutrientes y temperatura del suelo, en tres tipos de labranzas. W Pavan, desarrolló una herramienta simple de apoyo a la toma de decisiones de siembra, que permite reducir el riesgo de eventos climáticos extremos, y combina información disponible de acceso gratuito, en una interfaz sencilla para la evaluación en tiempo real. Esta herramienta está diseñada para ser utilizada por los productores, antes de la temporada de crecimiento y permite estimar y minimizar la probabilidad de eventos climáticos extremos durante las etapas críticas del desarrollo del cultivo [33].

En [34], presentan un modelo microclimático de un invernadero con ventilación natural para un cultivo de pepino. En este modelo se tuvo en cuenta los procesos de transferencia de calor y masa (convección, radiación, transpiración y ventilación natural) y se resolvió a través del software Simulink de MATLAB, mostrando un rendimiento óptimo en la evaluación estadística que comparo los datos pronosticados con los datos observados. En [35], desarrollaron 2 métodos diferentes, basados en datos de detección remota para predecir el rendimiento del trigo, el primero es un método de regresión simple entre diferentes índices de vegetación y el rendimiento del grano, y el segundo un método de modelo de cultivo basado en la optimización de dos parámetros (nitrógeno foliar específico y biomasa superficial inicial).

En [36], proponen un modelo de programación matemática (MMP) para la optimización de decisiones de patrones de cultivos, donde se consideraron variables como el transporte del cultivo, consumos de agua y energía. Para evaluar el modelo propuesto, se seleccionaron tierras cultivables en 23 condados de la provincia de Isfahan en (Irán). En [37], los autores proponen un algoritmo matemático para determinar fechas de madurez e acuerdo a la ubicación; a grandes rasgos al algoritmo se le da una fecha de siembra y las condiciones climáticas, y el devuelve una fecha de madurez adecuada, basada en los parámetros fisiológicos del cultivo y los principios agronómicos. Finalmente se presenta el trabajo [38], en el cual los autores presentan un método para identificar los parámetros de entrada más influyentes en un modelo desarrollado en sistemas de cultivo de maíz en la llanura del norte de China; para este caso en particular, se trabajó sobre los parámetros del rendimiento del cultivo, el nitrógeno del grano (N), la evapotranspiración y la lixiviación de nitrógeno.

■ ***Modelos de Cultivos a través de Sistemas difusos***

Por otra parte, se encontró en la literatura modelos de simulación de cultivos llevado a cabo a través de sistemas difusos. En el trabajo desarrollado por, T. Semeraro, se elaboró un sistema experto difuso para combinar Índice de Vegetación

Mejorada (EVI) e Índice de Agua de Superficie Terrestre (LSWI), obteniendo un nuevo índice combinado (Índice de vegetación difusa específico para cada caso), que representa mejor el Índice de Área de la Hoja (LAI) en comparación con los índices individuales [39]. En este mismo sentido G. Prabakaran, desarrolló un sistema de apoyo para mejorar la productividad de los cultivos y hacer uso eficiente de fertilizantes a través de lógica difusa. Para desarrollar este modelo se realizaron entrevistas con agricultores expertos, con conocimiento de agua, suelo y agronomía; y esta información se contrastó con informes técnicos de los minerales orgánicos que carecen en el suelo [40].

En el trabajo realizado por A. Guillermina, desarrollaron un sistema neuro difuso para un cultivo hidropónico de tomate, que controla la humedad del suelo mediante un riego automatizado. Este modelo utiliza una red neuronal tipo *feedforward* con algoritmo *backpropagation* (topología multicapa) y el sistema difuso tipo *Takagi-Sugeno* [41]. De modo similar S. Kolhe, desarrolló un sistema inteligente de diagnóstico de enfermedades en los cultivos, que utiliza un nuevo enfoque que se basa en el uso de una metodología de organización de las reglas. Este enfoque permite la elaboración de inferencias con la inteligencia mejorada y también incorpora nuevas características que mejoran los sistemas expertos actualmente existentes.

El sistema fue probado para tres cultivos de semillas oleaginosas: soja, maní y mostaza [42]. Y finalmente en el trabajo realizado por M. Toseef, desarrollaron una aplicación móvil inteligente para el diagnóstico de enfermedades de los cultivos en Pakistán. El sistema básicamente cuenta con una serie de información que a través de reglas de inferencia, puede comunicarle en su propio idioma a los granjeros en Pakistán y ayudarlos a diagnosticar enfermedades en sus cultivos [43].

■ Redes Neuronales Artificiales RNA

Otra forma de modelar y simular comportamientos de los cultivos es a través de RNA. En este sentido D. Patricio, presenta una revisión sistemática que apunta a identificar la aplicabilidad de las RNA y la visión por computador aplicadas en la agricultura de precisión para la producción de los cinco granos más producidos en el mundo: maíz, arroz, trigo, soja y cebada; en el trabajo se analizan 25 artículos publicados en los últimos 5 años y como conclusión se muestran las grandes oportunidades, que se tienen con las RNA, aplicadas a la agricultura de precisión, especialmente en la construcción de métodos sólidos de visión por computador [44].

Por su parte T. Chavan presenta AgroAVNET, un sistema para la clasificación de las especies de malezas y cultivos mediante

el uso de redes neuronales convolucionales¹ [45]. J. Hernández, desarrolló un modelo computacional para la evaluación de la calidad del agua en granjas de cultivo extensivo de camarón *Litopenaeus vannamei*; el sistema se realizó mediante el uso de redes neuronales artificiales, las cuales crean un indicador de la calidad del agua, permitiendo establecer una relación entre la dinámica de los parámetros del ecosistema y diferentes estados para el cultivo de la especie. La información del sistema se trabajó a partir de cuatro parámetros medioambientales, temperatura del agua, pH, oxígeno disuelto y salinidad [46]. K. Espinoza, desarrolló un sistema que combina el procesamiento de imágenes y redes neuronales artificiales para la detección y el monitoreo de la mosca blanca (*Bemisia tabaci*) en invernaderos. El proceso de modelado se realizó mediante un algoritmo de procesamiento de imágenes [47].

Otros trabajos como el presentado por A. Gabriela, desarrollan aplicaciones para el reconocimiento de patrones, utilizando redes neuronales artificiales para analizar señales de fluorescencia clorofílica (FC), con el fin de identificar y clasificar grupos de plantas cultivadas en medios hidropónicos que contienen diferentes cantidades de nitrógeno (N) [48]. En esta misma línea, A. Haghverdi, desarrolló un modelo para la predicción del rendimiento de la fibra de algodón, a partir de la fenología de los índices de cultivos utilizando redes neuronales artificiales [49]. Por otra parte A. Castañeda, diseñaron e implementaron una red neuronal artificial que usa perceptrones, en una estructura multicapa, entrenada por un algoritmo de propagación *Levenberg-Marquardt*, para el control inteligente de heladas en invernaderos en la región central de México, utilizando como variables la temperatura del aire exterior, humedad relativa del aire exterior, velocidad del viento, radiación solar y humedad relativa del aire en el interior como variables de entrada [50].

Finalmente, en el trabajo desarrollado por A. Villaseñor, se desarrolló un sistema para la predicción de heladas para la región agrícola de Salvatierra, Guanajuato. El sistema se basa en una red neuronal que es entrenada usando algunas variables atmosféricas para la predicción de temperaturas, luego, estas son utilizadas para predecir posibles daños en cultivos de la región [51].

■ Deep Reinforcement Learning

Recientemente los principios de aprendizaje profundo y aprendizaje por refuerzo se vienen utilizando para la construcción de modelos que facilitan la toma de decisiones inteligentes en tiempo real, por ejemplo, para determinar la cantidad de agua necesaria en sistemas de riego o estimar la cantidad de nutrientes que mejoren el entorno de crecimiento

¹ Una red neuronal convolucional es un tipo de red neuronal artificial donde las neuronas corresponden a campos receptivos de una manera muy similar a las neuronas en la corteza visual primaria (V1) de un cerebro biológico. Este tipo de red es una variación de un perceptrón

multicapa, y son muy efectivas para tareas de visión artificial, como en la clasificación y segmentación de imágenes, entre otras aplicaciones [85]

de los cultivos. En [52], los autores presentan un sistema de IoT de agricultura inteligente basado en el aprendizaje de refuerzo profundo que incluye cuatro etapas: recopilación de datos agrícolas, computación de borde, transmisión de datos agrícolas y computación en la nube.

El sistema integra algunas técnicas de información avanzadas, especialmente inteligencia artificial y computación en la nube, con la producción agrícola para aumentar la producción y el rendimiento. De otra parte en [53], los autores integran algunas técnicas de información y comunicaciones avanzadas, imágenes multiespectrales tomadas con drones, de donde se obtiene información para generar un modelo que utiliza aprendizaje profundo y clasificación AdaBoost para el reconocimiento de enfermedades en arboles de pino. En [54], los autores propone un enfoque que utiliza el aprendizaje por transferencia con extracción de características para construir un sistema de identificación de la enfermedad del mildiú, basado en el modelo VGG16 de CNN. El aprendizaje profundo facilita un análisis de datos rápido para tomar decisiones y prevenir la enfermedad. El resultado experimental muestra una precisión del 95,00%.

En [2], los autores realizaron una revisión sobre referente a la predicción del rendimiento de cultivos mediante el aprendizaje automático, en el documento los autores concluyen que los algoritmos de aprendizaje profundo más utilizados últimamente en los estudios para la predicción de sistemas agrícolas, son las redes neuronales convolucionales (CNN) seguidos de otros algoritmos como son la memoria a largo plazo (LSTM) y las redes neuronales profundas (DNN).

■ Estimación de Nitrógeno con el apoyo de modelos predictivos, imágenes multiespectrales y sensores.

Sin embargo, estos enfoques requieren el procesamiento de enormes ca Las imágenes multiespectrales y los sensores en campo se están utilizando ampliamente en la construcción de herramientas de apoyo a la toma de decisiones para los sistemas agrícolas contemporáneos para mejorar la producción, el rendimiento y la gestión del nitrógeno.

ntidades de datos de detección remota desde diferentes plataformas, por lo tanto, actualmente se está prestando mayor atención a los métodos de aprendizaje automático (ML). Esto se debe a la capacidad de los sistemas basados en aprendizaje automático para procesar una gran cantidad de entradas y manejar tareas no lineales [4].

Las técnicas de aprendizaje automático aplicadas a los datos de imágenes hiperespectrales se pueden utilizar para revelar características fisiológicas y estructurales en las plantas y permitir el seguimiento de la dinámica fisiológica debido a los efectos ambientales, demostraron que los datos de campo, como la humedad del suelo, el clima, las características de riego y el rendimiento resultante, podrían fusionarse mediante técnicas de ML para proporcionar recomendaciones automatizadas para el riego [55].

En la Tabla 3 se presentan una revisión de estudios recientes en el área de predicción del rendimiento de cultivos y estimación del estado de N, que incorporan diferentes técnicas de ML.

TABLA I. TRABAJOS REVISADOS SOBRE TECNOLOGÍAS IoT APLICADAS A LA AGRICULTURA.

Objetivo	Solución propuesta	Tecnologías	Ref.
Realizar predicciones de patrones de riego basados en escenarios climáticos.	Red de sensores inalámbricos distribuidos (WSN), los cuales transmitieron los datos a un servidor común	(WSN), (ML)	[25]
Reconocimiento práctico de enfermedades en los cultivos a través de variables agrometeorológicas	Aplicaciones IoT para monitorear y transmitir información de variables climáticas para el reconocimiento práctico de enfermedades en los cultivos.	Multi-Context Fusion Network (MCFN)	[26]
Predecir de forma temprana las condiciones que conducen al brote de enfermedades epidémicas en los cultivos	Sistema de monitoreo basado en sensores en red, utiliza aprendizaje de máquina.	(WSN), (ML)	[27]
Monitorear la temperatura del aire, la humedad y la intensidad de la luz ambiental en un cultivo con el fin de medir y controlar diferentes parámetros.	Implementación de una red de sensores inalámbricos para monitorear las variables. El sistema se implementó en un campo de berenjenas	(WSN), (ML)	[28]
Adquirir datos, monitorear y controlar procesos agroindustriales.	La plataforma software recibe datos de sensores instalados en campo y genera alertas tempranas vía SMS, llamadas de voz o correo electrónico	(WSN)	[29]
Aumentar los rendimientos y reducir el tiempo de respuesta a través de la manipulación de la luz en la planta.	Manipulación de parámetros de diodos emisores de luz (LED) que incluyen espectros, fotepe riodo e intensidad de luz	Sensores, tecnología LED	[30]

Fuente: Elaboración propia

TABLA II. TRABAJOS REVISADOS SOBRE TECNOLOGÍAS IoT APLICADAS A LA AGRICULTURA.

<i>spectos clave</i>	<i>Cultivos</i>	<i>Título</i>	<i>Año</i>	<i>Fuentes</i>	
				Revisado	Ref.
Estimación de biomasa utilizando vehículos aéreos no tripulados (UAV)	Arroz	High-Throughput Biomass Estimation in Rice Crops Using UAV Multispectral Imagery	2019	Science direct	[10]
Índice de vegetación NDVI para determinar el crecimiento de cultivos	Café de castilla	Analysis of Normalized Vegetation Index in Castile Coffee Crops , Using Mosaics of Multispectral Images Acquired by Unmanned Aerial Vehicle (UAV)	2020	Science direct	[11]
Crop Water Stress Index (CWSI)	Calabaza, berenjena.	Assessment for crop water stress with infrared thermal imagery in precision agriculture: A review and future prospects for deep learning applications	2021	Science direct	[56]
Diagnóstico del estado del nitrógeno en cultivos a partir de imágenes	Maíz	Diagnosis of nitrogen status in winter oilseed rape (Brassica napus L.) using in-situ hyperspectral data and unmanned aerial vehicle (UAV) multispectral images	2018	Science direct	[57]
Algoritmo LS-SVM para construir modelos entre los índices de vegetación y el contenido de nitrógeno.	Pepino	Correlations between Nitrogen Content and Multispectral Image of Greenhouse	2018	Science direct	[16]
UAV y crecimiento del arroz para mejorar la predicción del rendimiento de grano.	Arroz	Grain yield prediction of rice using multi-temporal UAV-based RGB and multispectral images and model transfer – a case study of small farmlands in the South of China	2020	Science direct	[58]
UAV y un modelo para estimar el nivel de nutrición de nitrógeno en el maíz	Maiz	UAV Technology and Machine Learning Techniques applied to the Yield Improvement in Precision Agriculture	2017	IEEE Xplore	[15]
Imágenes multiespectrales para predecir el contenido de azúcar de las manzanas "Fuji".	Manzana	Multispectral imaging for predicting sugar content of 'Fuji' apples	2018	Science direct	[19]
Mapeo de suelos basado en las relaciones entre el crecimiento vegetativo y la fertilidad del suelo.	Semilla oleaginosa	Mapping field-scale soil organic carbon with unmanned aircraft system- acquired time series multispectral images	2020	Science direct	[18]
Índices (VI) Detección de enfermedades - Citrus Huanglongbing (HLB)	Cítricos	Comparison of machine learning methods for citrus greening detection on UAV multispectral images	2020	Science direct	[20]
Cuantificar la calidad del fruto	Granadilla	Determining quality and maturity of pomegranates using multispectral imaging	2017	Science direct	[21]
Imagen térmica multiespectral basada en teléfonos móviles y UAV para evaluar el rendimiento de riego de cultivos de berenjena.	Berenjena africana	The feasibility of hand-held thermal and UAV-based multispectral imaging for canopy water status assessment and yield prediction of irrigated African eggplant (Solanum aethopicum L)	2021	Science direct	[59]
Método de caracterización automática de la calidad de las semillas basado en la combinación de tecnologías de imagen multiespectral y de rayos X	oilseed plant (Jatropha curcas)	Multispectral and X-ray images for characterization of Jatropha curcas L. seed quality	2021	Scopus	[60]
Cartografiar la evapotranspiración (ETa) de un huerto comercial de manzanas utilizando UAV basado en imágenes térmicas y multiespectrales	Manzana	Spatiotemporal water use mapping of a commercial apple orchard using UAS based spectral imagery	2020	Science direct	[61]
Medir de forma precisa, rápida, estable y no destructiva los niveles de NPK en las plantas de tomate	Tomate	Nondestructive Determination of Nitrogen, Phosphorus and Potassium Contents in Greenhouse Tomato Plants Based on Multispectral Three-Dimensional Imaging	2019	Scopus	[62]
Estimar el rendimiento y defectos de la naranja, utilizando dos sistemas de imágenes de reflectancia hiperespectral, uno que funciona en el rango de 400 a 1000 nm (visible / infrarrojo cercano, Vis / NIR) y el otro entre 900 y 2500 nm (infrarrojo de onda corta, SWIR).	Citricos Naranja	Setting up a methodology to distinguish between green oranges and leaves using hyperspectral imaging	2019	Science direct	[63]
Método automático para estimar la fecha de recolección del trigo a partir de imágenes diarias adquiridas por una cámara RGB fija en el campo.	Trigo	An automatic method based on daily in situ images and deep learning to date wheat heading stage	2020	Science direct	[64]
Modelo de registro multicapa de imágenes heterogéneas obtenidas por un vehículo aéreo no tripulado (UAV). Proponen un método de registro invariante a las diferencias de intensidad, lo permite conectar diferentes imágenes aéreas con diferencias significantes.	plantación de olivos	A framework for registering UAV-based imagery for crop-tracking in Precision Agriculture	2021	Science direct	[65]
Proponen un nuevo árbol de decisión (DT) que combina características de textura (media y varianza (CV)) y características espectrales (TS-DT) para la detección de plantas de arroz en imágenes de UAV.	Arroz	Early season detection of rice plants using RGB, NIR-G-B and multispectral images from unmanned aerial vehicle (UAV)	2020	Science direct	[66]

TABLA II. MODELOS PREDICTIVOS, IMÁGENES MULTIESPECTRALES Y SENSORES EN LA ESTIMACIÓN DE NITRÓGENO EN DIFERENTES CULTIVOS.

<i>Aspectos clave</i>	<i>Cultivos</i>	<i>Título</i>	<i>Año</i>	<i>Fuentes</i>	
				Revisado de Science direct	Ref. [67]
En este estudio se utiliza LiDAR montado en UAV y sensores de imágenes multiespectrales para monitorear dos ensayos de campo de caña de azúcar con aportes variables de fertilización con nitrógeno (N)	Caña de azúcar	Fine-scale prediction of biomass and leaf nitrogen content in sugarcane using UAV LiDAR and multispectral imaging	2020		
En este estudio, se utilizó la regresión de vectores de soporte de múltiples núcleos (MK-SVR) para evaluar el LNC en el trigo basándose en datos de teledetección satelital. Los objetivos de este estudio fueron (1) investigar la aplicabilidad del algoritmo MK-SVR para estimar remotamente el LNC en trigo, (2) probar el desempeño del modelo de regresión MK-SVR.	Trigo	Estimation of leaf nitrogen concentration in wheat using the MK-SVR algorithm and satellite remote sensing data	2017	Science direct	[68]
Se estima la variación espacial de la concentración de nitrógeno del dosel de la caña de azúcar (CNC) utilizando datos espectrales, que se midieron a partir de una imagen hiperspectral transmitida por el espacio. Se aplicaron Regresión lineal múltiple escalonada (SMLR) y Regresión de vectores de soporte (SVR) para calibrar y validar los modelos de estimación CNC.	Caña de azúcar	Estimations of Nitrogen Concentration in Sugarcane Using Hyperspectral Imagery	2018	Scopus	[69]
Revisión de estudios y trabajos relacionados con la estimación de nitrógeno a través de imágenes hiperspectrales. Se presentan metodologías para minimizar los efectos de confusión y mejorar la sensibilidad de la reflectancia del dosel hacia el estado del nitrógeno del cultivo.	Diversos cultivos	An overview of crop nitrogen status assessment using hyperspectral remote sensing: Current status and perspectives	2021	Science direct	[70]
Se propuso el algoritmo LS-SVM para construir modelos entre los índices de vegetación y el contenido de nitrógeno. Los resultados mostraron que el método de cámara CCD con filtros para obtener imágenes multiespectrales puede usarse para analizar contenido de nitrógeno de las hojas de pepino.	Pepino	Correlations between Nitrogen Content and Multispectral Image of Greenhouse	2018	Science direct	[16]
Métodos de Aprendizaje automático para mejorar la predicción de Nitrógeno a través del índice de nutrición de N del maíz (NNI) y mejorar el rendimiento de grano mediante la combinación de datos de suelo, clima y manejo con datos de sensores activos mediante regresión forestal aleatoria (RFR).	Maíz	Machine learning-based in-season nitrogen status diagnosis and side-dress nitrogen recommendation for corn	2021	Science direct	[55]
En este estudio, el modelo PROSPECT original se amplió reemplazando el coeficiente de absorción de clorofila por un coeficiente de absorción N equivalente para desarrollar un modelo PROSPECT basado en nitrógeno (N-PROSPECT). N-PROSPECT se evaluó comparando los valores de reflectancia simulados por el modelo con los valores de reflectancia foliar medidos.	Trigo	Leaf nitrogen spectral reflectance model of winter wheat (Triticum aestivum) based on PROSPECT: simulation and inversion	2017	Scopus	[71]
Evaluar la relación entre la concentración de nutrientes en la savia del pecíolo y diferentes variables agronómicas y climáticas para un cultivo de tomate en invernadero en condiciones mediterráneas. Así mismo se determinó las concentraciones de nitrógeno, P, K, Cl y Na en la hoja.	Tomate	Approach to Petiole Sap Nutritional Diagnosis Method by Empirical Model Based on Climatic and Growth Parameters	2019	Scopus	[72]
En este estudio, se construyó un modelo N-PROSAIL basado en el modelo PROSPECT basado en N y el modelo de dosel del modelo SAIL y se utilizó para recuperar el estado de N del cultivo tanto a escala de hoja como de dosel.	Trigo	Remote Sensing of Leaf and Canopy Nitrogen Status in Winter Wheat (Triticum aestivum L.) Based on N-PROSAIL Model	2018	Springer	[73]
Diagnóstico de nutrientes de las plantas a partir de métodos tradicionales y las herramientas modernas de diagnóstico de nutrientes. Se abordan técnicas de medición de nitrógeno incluyendo técnicas que abordan Big data, machine Learning e inteligencia artificial.	Varios	Diagnosis of nutrient composition in fruit crops: Major developments	2020	Science direct	[74]
En este estudio, se construyeron múltiples tablas de búsqueda (Multi-LUT), los cuales se construyeron con base al modelo N-PROSAIL. El objetivo es utilizar los Multi-LUT para estimar la densidad de N del dosel (CND) en el trigo de invierno.	Trigo	Multi-LUTs method for canopy nitrogen density estimation in winter wheat by field and UAV hyperspectral	2019	Science direct	[75]
Enfoques basados en el monitoreo del suelo y las plantas que pueden ayudar a mejorar la gestión del nitrógeno. Estos incluyen el monitoreo del suelo, destructivo (análisis de N tisular, nitrato de savia de pecíolo (NO ₃ ⁻) y métodos no destructivos (sensores ópticos) de análisis rápido.	Hortalizas	Monitoring nitrogen status of vegetable crops and soils for optimal nitrogen management	2020	Science direct	[76]

<p>Proponen un nuevo enfoque para estimar el LNC en naranjos de Valencia aplicando algoritmos de análisis espectral en imágenes multiespectrales de alta resolución espacial. Aquí se muestra una precisión superior al 87% en la determinación del LNC en naranjo de Valencia.</p> <p>Aplicación de la espectroscopia de infrarrojo cercano (NIRS) relacionada con el manejo de la detección y el control de calidad de frutos y el contenido de macro y microcomponentes.</p> <p>Este documento introduce un marco para la teledetección hiperespectral del N de los cultivos de cereales, basado en un estudio exhaustivo de la literatura, para ayudar a informar las mejores prácticas de seguimiento.</p> <p>Proporcionan un estado de la técnica. descripción general del arte de los métodos de recuperación de N de cultivos a partir de datos hiperespectrales en el sector agrícola y en el contexto de futuras misiones de espectroscopía de imágenes por satélite.</p> <p>Este documento analiza los desarrollos de investigación realizados en los últimos 15 años sobre técnicas basadas en el aprendizaje automático para la predicción precisa del rendimiento de los cultivos y la estimación del estado del nitrógeno.</p> <p>Este artículo propuso un modelo de estimación del contenido total de nitrógeno (TNC) en hojas de sándalo que toma la estación de muestreo y las condiciones del sitio como variable ficticia y efecto aleatorio, respectivamente.</p> <p>Este estudio evaluó el rendimiento de los datos adquiridos de imágenes utilizando un sistema de imágenes basado en un vehículo aéreo no tripulado (UAV) para estimar el rendimiento del maíz (Zea mays L.) y los efectos de la aplicación de tasa variable de nitrógeno (N) en los cultivos.</p> <p>En este estudio se presentó el método de la máquina de aprendizaje de color sintético (SCLM), para mejorar la precisión de la estimación de Nitrógeno Total (TN). Este método combina conceptos de aprendizaje automático con funciones de decoloración rápida.</p> <p>Este estudio presenta un método de recuperación híbrido que utiliza un enfoque basado en la física combinado con una regresión de aprendizaje automático para estimar el contenido de N del cultivo.</p>	Naranja	Improvement of leaf nitrogen content inference in Valencia-orange trees applying spectral analysis algorithms in UAV mounted-sensor images	2019	Science direct	[77]
	Frutas	NIR spectroscopy and management of bioactive components, antioxidant activity, and macronutrients in fruits	2020	Science direct	[78]
	Cereales	Progress of hyperspectral data processing and modelling for cereal crop nitrogen monitoring	2020	Science direct	[79]
	Artículo de revisión	Crop nitrogen monitoring: Recent progress and principal developments in the context of imaging spectroscopy missions	2020	Science direct	[80]
	Artículo de revisión	Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture	2018	Science direct	[81]
	Sándalo	Model for estimation of total nitrogen content in sandalwood leaves based on nonlinear mixed effects and dummy variables using multispectral images	2019	Science direct	[17]
	Maíz	Estimation of maize yield and effects of variable-rate nitrogen application using UAV-based RGB imagery	2019	Science direct	[82]
	Suelos en general	Estimation of soil total nitrogen using the synthetic color learning machine (SCLM) method and hyperspectral data	2020	Science direct	[83]
	Trigo	Retrieval of aboveground crop nitrogen content with a hybrid machine learning method	2020	Science direct	[84]

V. DISCUSIÓN

La teledetección óptica del estado del N de la planta es un método no destructivo basado en la reflectancia del dosel en las longitudes de onda NIR visibles (400-900 nm). Esta medición se completa in situ, lo que reduce la cantidad de muestras de campo necesarias y, por lo tanto, reduce el tiempo y el costo financiero de la recolección, preparación y análisis de laboratorio de las muestras de campo. Se han dedicado muchos estudios a la medición no destructiva del estado de N que se infiere en plantas mediante tecnología de teledetección y los índices espectrales indicativos del estado del N de la planta se han derivado de datos hiperespectrales.

El documento concluye que los rápidos avances en las tecnologías de detección y las técnicas de ML proporcionarán soluciones rentables e integrales para una mejor estimación del estado de los cultivos y el medio ambiente y la toma de decisiones. Aplicación más específica de las plataformas de sensores y técnicas ML, la fusión de diferentes modalidades de sensores y conocimiento experto,

VI. CONCLUSIONES.

Se puede concluir, de acuerdo con la revisión del estado del arte, que la Redes Neuronales Artificiales, es el modelo computacional más utilizado para la construcción de sistemas de predicción que permiten la estimación de nutrientes, detección de enfermedades y plagas, programación de sistemas de riego, así como para la clasificación de frutos entre otras aplicaciones. Estos sistemas pueden usar diversas fuentes de información como imágenes multiespectrales, sensores en campo, pruebas de laboratorio para llevar a cabo el proceso de predicción.

Por otra parte, este estudio mostró que las publicaciones seleccionadas utilizan una variedad de características, dependiendo del alcance de la investigación y la disponibilidad de datos. Cada artículo investiga la predicción de rendimiento con aprendizaje automático, pero difiere de las características. Los estudios también difieren en escala, posición geológica y cultivo. La elección de características depende de la disponibilidad del conjunto de datos y el objetivo de la investigación. Se han utilizado muchos algoritmos en diferentes estudios. Los resultados muestran que no se puede sacar una conclusión específica sobre cuál es el mejor modelo, pero muestran claramente que algunos modelos de aprendizaje automático se utilizan más que otros. En cuanto a las imágenes multiespectrales se puede concluir en los trabajos relacionados que son una buena alternativa para la estimación de nitrógeno ya que las deficiencias de nitrógeno se relacionan directamente con el nivel de clorofila y este a su vez está asociado con el color del cultivo.

VII. REFERENCIAS

- [1] D. Tranfield, D. Denyer, and P. Smart, "Towards a Methodology for Developing Evidence-Informed Management Knowledge by Means of Systematic Review," *Br. J. Manag.*, vol. 14, no. 3, pp. 207–222, Sep. 2003, doi: 10.1111/1467-8551.00375.
- [2] T. van Klompenburg, A. Kassahun, and C. Catal, "Crop yield prediction using machine learning: A systematic literature review," *Comput. Electron. Agric.*, vol. 177, p. 105709, Oct. 2020, doi: 10.1016/j.compag.2020.105709.
- [3] K. Spanaki, U. Sivarajah, M. Fakhimi, S. Despoudi, and Z. Irani, "Disruptive technologies in agricultural operations: a systematic review of AI-driven AgriTech research," *Ann. Oper. Res.*, pp. 1–34, Jan. 2021, doi: 10.1007/s10479-020-03922-z.
- [4] A. Chlingaryan, S. Sukkarieh, and B. Whelan, "Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture: A review," *Computers and Electronics in Agriculture*, vol. 151, Elsevier B.V., pp. 61–69, 01-Aug-2018, doi: 10.1016/j.compag.2018.05.012.
- [5] A. D. Boursianis *et al.*, "Internet of Things (IoT) and Agricultural Unmanned Aerial Vehicles (UAVs) in smart farming: A comprehensive review," *Internet of Things*, p. 100187, Mar. 2020, doi: 10.1016/j.iot.2020.100187.
- [6] B. Li, J. Lecourt, and G. Bishop, "Advances in Non-Destructive Early Assessment of Fruit Ripeness towards Defining Optimal Time of Harvest and Yield Prediction—A Review," *Plants*, vol. 7, no. 1, p. 3, Jan. 2018, doi: 10.3390/plants7010003.
- [7] R. Beulah, "A Survey on Different Data Mining Techniques for Crop Yield Prediction," *Int. J. Comput. Sci. Eng.*, vol. 7, no. 1, pp. 738–744, 2019, doi: 10.26438/ijcse/v7i1.738744.
- [8] L. Karthikeyan, I. Chawla, and A. K. Mishra, "A review of remote sensing applications in agriculture for food security: Crop growth and yield, irrigation, and crop losses," *J. Hydrol.*, vol. 586, p. 124905, Jul. 2020, doi: 10.1016/j.jhydrol.2020.124905.
- [9] M. Weiss, F. Jacob, and G. Duveiller, "Remote sensing for agricultural applications: A meta-review," *Remote Sens. Environ.*, vol. 236, no. December 2018, p. 111402, 2020, doi: 10.1016/j.rse.2019.111402.
- [10] C. A. Devia, J. P. Rojas, E. P. Carol, M. Ivan, F. M. D. Patino, and J. Colorado, "High-Throughput Biomass Estimation in Rice Crops Using UAV Multispectral Imagery," *J. Intell. Robot. Syst.*, 2019.
- [11] J. Mej and J. G. Narvaez, "Analysis of Normalized Vegetation Index in Castile Coffee Crops , Using Mosaics of Multispectral Images Acquired by Unmanned Aerial Vehicle (UAV)," *Commun. Comput. Inf. Sci. First Int. Conf. ICAT 2019*, pp. 546–559, 2020.
- [12] A. Berger, G. Ettlin, C. Quincke, and P. Rodríguez-

- Bocca, "Predicting the Normalized Difference Vegetation Index (NDVI) by training a crop growth model with historical data," *Comput. Electron. Agric.*, no. April, pp. 0–1, 2018, doi: 10.1016/j.compag.2018.04.028.
- [13] G. Kiti, A. Tagarakis, N. Cselyuska, M. Pani, S. Birgermajer, and J. Matovi, "Original papers A new low-cost portable multispectral optical device for precise plant status assessment," *Comput. Electron. Agric.*, vol. 162, no. January, pp. 300–308, 2019, doi: 10.1016/j.compag.2019.04.021.
- [14] H. Kirnak, H. A. Irik, and A. Unlukara, "Potential use of crop water stress index (CWSI) in irrigation scheduling of drip-irrigated seed pumpkin plants with different irrigation levels," *Sci. Hortic. (Amsterdam)*, vol. 256, p. 108608, Oct. 2019, doi: 10.1016/j.scienta.2019.108608.
- [15] J. A. Arroyo *et al.*, "UAV Technology and Machine Learning Techniques applied to the Yield Improvement in Precision Agriculture," *IEEE Mex. Humanit. Technol. Conf. (MHTC)*, no. 3, 2017.
- [16] W. Yang, N. Sigrimis, M. Li, H. Sun, and L. Zheng, "Correlations between Nitrogen Content and Multispectral Image of Greenhouse," *IFIP Int. Fed. Inf. Process.*, pp. 456–463, 2018.
- [17] Z. Chen and X. Wang, "Chemometrics and Intelligent Laboratory Systems Model for estimation of total nitrogen content in sandalwood leaves based on nonlinear mixed effects and dummy variables using multispectral images," *Chemom. Intell. Lab. Syst.*, vol. 195, no. October, p. 103874, 2019, doi: 10.1016/j.chemolab.2019.103874.
- [18] L. Guo *et al.*, "Mapping field-scale soil organic carbon with unmanned aircraft system- acquired time series multispectral images," *Soil Tillage Res.*, vol. 196, no. August 2019, p. 104477, 2020, doi: 10.1016/j.still.2019.104477.
- [19] C. Tang, H. He, E. Li, and H. Li, "Multispectral imaging for predicting sugar content of 'Fuji' apples," *Opt. Laser Technol.*, vol. 106, pp. 280–285, 2018, doi: 10.1016/j.optlastec.2018.04.017.
- [20] Y. Lan, Z. Huang, X. Deng, Z. Zhu, and H. Huang, "Comparison of machine learning methods for citrus greening detection on UAV multispectral images," *Comput. Electron. Agric.*, vol. 171, no. July 2019, p. 105234, 2020, doi: 10.1016/j.compag.2020.105234.
- [21] R. Khodabakhshian, B. Emadi, M. Khojastehpour, and M. R. Golzarian, "Determining quality and maturity of pomegranates using multispectral imaging," *J. Saudi Soc. Agric. Sci.*, vol. 16, no. 4, pp. 322–331, Oct. 2017, doi: 10.1016/j.jssas.2015.10.004.
- [22] A. D. Boursianis *et al.*, "Internet of Things (IoT) and Agricultural Unmanned Aerial Vehicles (UAVs) in smart farming: A comprehensive review," *Internet of Things*, p. 100187, Mar. 2020, doi: 10.1016/j.iot.2020.100187.
- [23] A. Brook *et al.*, "Remote Sensing of Environment A smart multiple spatial and temporal resolution system to support precision agriculture from satellite images : Proof of concept on Aglianico vineyard," *Remote Sens. Environ.*, vol. 240, no. January, p. 111679, 2020, doi: 10.1016/j.rse.2020.111679.
- [24] C. M. Sicre, R. Fieuzal, and F. Baup, "Int J Appl Earth Obs Geoinformation Contribution of multispectral (optical and radar) satellite images to the classification of agricultural surfaces," *Int J Appl Earth Obs Geoinf.*, vol. 84, no. September 2018, p. 101972, 2020, doi: 10.1016/j.jag.2019.101972.
- [25] A. Vij, S. Vijendra, A. Jain, S. Bajaj, A. Bassi, and A. Sharma, "IoT and Machine Learning Approaches for Automation of Farm Irrigation System," in *Procedia Computer Science*, 2020, vol. 167, pp. 1250–1257, doi: 10.1016/j.procs.2020.03.440.
- [26] Y. Zhao *et al.*, "An effective automatic system deployed in agricultural Internet of Things using Multi-Context Fusion Network towards crop disease recognition in the wild," *Appl. Soft Comput. J.*, vol. 89, p. 106128, 2020, doi: 10.1016/j.asoc.2020.106128.
- [27] A. Khattab, S. E. D. Habib, H. Ismail, S. Zayan, Y. Fahmy, and M. M. Khairy, "An IoT-based cognitive monitoring system for early plant disease forecast," *Comput. Electron. Agric.*, vol. 166, p. 105028, Nov. 2019, doi: 10.1016/j.compag.2019.105028.
- [28] S. Verma, N. Chug, and D. V. Gadre, "Wireless sensor network for crop field monitoring," in *ITC 2010 - 2010 International Conference on Recent Trends in Information, Telecommunication, and Computing*, 2010, pp. 207–211, doi: 10.1109/ITC.2010.21.
- [29] F. A. Chaparro, Jorge E; Riaño, Jairo A; León, "AgriculTIC, plataforma web para el desarrollo de procesos agroindustriales a partir de herramientas de Internet of Underground Things (IOUT)," *Rev. Espac.*, vol. 40, no. 37, pp. 1–14, 2019.
- [30] A. N. Harun, N. Mohamed, R. Ahmad, A. R. A. Rahim, and N. N. Ani, "Improved Internet of Things (IoT) monitoring system for growth optimization of Brassica chinensis," *Comput. Electron. Agric.*, Jun. 2019, doi: 10.1016/J.COMPAG.2019.05.045.
- [31] D. Wallach, D. Makowski, J. W. Jones, and F. Brun, *Basics of Agricultural System Models*, Third Edit. Gainesville, FL, United States: Elsevier B.V. or its licensors or contributors. ScienceDirec, 2019.
- [32] M. Dahmardeh and A. Hadiani, "Assessment of soil elements in intercropping based on mathematical modelling," *Comput. Electron. Agric.*, vol. 122, pp. 218–224, Mar. 2016, doi: 10.1016/j.compag.2016.01.036.
- [33] W. Pavan *et al.*, "Crop season planning tool: Adjusting sowing decisions to reduce the risk of extreme weather events," *Comput. Electron. Agric.*, vol. 156, no. November 2018, pp. 62–70, 2018, doi: 10.1016/j.compag.2018.11.013.
- [34] M. C. Singh, J. P. Singh, and K. G. Singh, "Development of a microclimate model for prediction

- of temperatures inside a naturally ventilated greenhouse under cucumber crop in soilless media,” *Comput. Electron. Agric.*, vol. 154, no. January, pp. 227–238, 2018, doi: 10.1016/j.compag.2018.08.044.
- [35] D. V. Gaso, A. G. Berger, and V. S. Ciganda, “Predicting wheat grain yield and spatial variability at field scale using a simple regression or a crop model in conjunction with Landsat images,” *Comput. Electron. Agric.*, 2019, doi: 10.1016/j.compag.2019.02.026.
- [36] M. Mardani Najafabadi, S. Ziaee, A. Nikouei, and M. Ahmadpour Borazjani, “Mathematical programming model (MMP) for optimization of regional cropping patterns decisions: A case study,” *Agric. Syst.*, vol. 173, no. June 2018, pp. 218–232, 2019, doi: 10.1016/j.agry.2019.02.006.
- [37] S. Minoli and D. B. Egli, “Modelling cropping periods of grain crops at the global scale,” *Glob. Planet. Change*, vol. 174, pp. 35–46, 2019, doi: 10.1016/j.gloplacha.2018.12.013.
- [38] M. Jabloun, C. Hu, F. Tao, X. Zhang, J. E. Olesen, and X. Li, “Sensitivity of simulated crop yield and nitrate leaching of the wheat-maize cropping system in the North China Plain to model parameters,” *Agric. For. Meteorol.*, vol. 263, no. March, pp. 25–40, 2018, doi: 10.1016/j.agrformet.2018.08.002.
- [39] T. Semeraro, G. Mastroleo, A. Pomes, A. Luvisi, E. Gissi, and R. Aretano, “Modelling fuzzy combination of remote sensing vegetation index for durum wheat crop analysis,” *Comput. Electron. Agric.*, vol. 156, no. December 2018, pp. 684–692, 2019, doi: 10.1016/j.compag.2018.12.027.
- [40] G. Prabakaran, D. Vaithyanathan, and M. Ganesan, “Fuzzy decision support system for improving the crop productivity and efficient use of fertilizers,” *Comput. Electron. Agric.*, vol. 150, no. March, pp. 88–97, 2018, doi: 10.1016/j.compag.2018.03.030.
- [41] A. Guillermina, C. Martínez, and I. T. D. T. Gutiérrez, “Neurofuzzy model for the soil moisture control in hydroponic crop for tomato plant .,” *Rev. Tecnol. Digit.*, vol. 6, no. 1, pp. 43–56, 2016.
- [42] S. Kolhe, R. Kamal, H. S. Saini, and G. K. Gupta, “A web-based intelligent disease-diagnosis system using a new fuzzy-logic based approach for drawing the inferences in crops,” *Comput. Electron. Agric.*, vol. 76, no. 1, pp. 16–27, 2011, doi: 10.1016/j.compag.2011.01.002.
- [43] M. Toseef and M. J. Khan, “An intelligent mobile application for diagnosis of crop diseases in Pakistan using fuzzy inference system,” *Comput. Electron. Agric.*, vol. 153, no. February, pp. 1–11, 2018, doi: 10.1016/j.compag.2018.07.034.
- [44] D. I. Patricio and R. Rieder, “Computer vision and artificial intelligence in precision agriculture for grain crops: A systematic review,” *Comput. Electron. Agric.*, vol. 153, no. August, pp. 69–81, 2018, doi: 10.1016/j.compag.2018.08.001.
- [45] T. R. Chavan and A. V. Nandedkar, “AgroAVNET for crops and weeds classification: A step forward in automatic farming,” *Comput. Electron. Agric.*, vol. 154, no. September, pp. 361–372, 2018, doi: 10.1016/j.compag.2018.09.021.
- [46] J. J. C. Hernández, L. P. S. Fernández, I. H. Bautista, and J. H. López, “Modelo basado en redes neuronales artificiales para la evaluación de la calidad del agua en sistemas de cultivo extensivo de camarón,” *Tecnol. y Ciencias del Agua*, vol. 8, no. 5, pp. 71–89, Oct. 2017.
- [47] K. Espinoza, D. L. Valera, J. A. Torres, A. López, and F. D. Molina-Aiz, “Combination of image processing and artificial neural networks as a novel approach for the identification of Bemisia tabaci and Frankliniella occidentalis on sticky traps in greenhouse agriculture,” *Comput. Electron. Agric.*, vol. 127, pp. 495–505, 2016, doi: 10.1016/j.compag.2016.07.008.
- [48] A. Gabriela, R. Maldonado, R. Echeverría, A. Gabriela, and R. Echeverría, “Artificial neural networks for evaluating nitrogen content in leguminous plants,” *Rev. Cienc. e Ing.*, vol. 36, 2015.
- [49] A. Haghverdi, R. A. Washington-Allen, and B. G. Leib, “Prediction of cotton lint yield from phenology of crop indices using artificial neural networks,” *Comput. Electron. Agric.*, vol. 152, no. May, pp. 186–197, 2018, doi: 10.1016/j.compag.2018.07.021.
- [50] A. Castañeda-Miranda and V. M. Castaño, “Smart frost control in greenhouses by neural networks models,” *Comput. Electron. Agric.*, vol. 137, pp. 102–114, 2017, doi: 10.1016/j.compag.2017.03.024.
- [51] Villaseñor Aguilar Marcos de Jesus, Montesillo Puente Francisco Javier, Samano Abone Obed Noe, Zuñiga Maldonado Walter Manuel, and Lopez Enriquez Renato, “Predicción de heladas en cultivos usando redes neuronales en la zona de Salvatierra Guanajuato,” *Rev. Ingenieros*, vol. 1, no. 1, pp. 58–65, 2017.
- [52] F. Bu and X. Wang, “A smart agriculture IoT system based on deep reinforcement learning,” *Futur. Gener. Comput. Syst.*, May 2019, doi: 10.1016/J.FUTURE.2019.04.041.
- [53] G. Hu, C. Yin, M. Wan, Y. Zhang, and Y. Fang, “Recognition of diseased Pinus trees in UAV images using deep learning and AdaBoost classifier,” *Biosyst. Eng.*, vol. 194, pp. 138–151, 2020, doi: 10.1016/j.biosystemseng.2020.03.021.
- [54] S. Coulibaly, B. Kamsu-Foguem, D. Kamissoko, and D. Traore, “Deep neural networks with transfer learning in millet crop images,” *Comput. Ind.*, vol. 108, pp. 115–120, 2019, doi: 10.1016/j.compind.2019.02.003.
- [55] X. Wang *et al.*, “Machine learning-based in-season nitrogen status diagnosis and side-dress nitrogen recommendation for corn,” *Eur. J. Agron.*, vol. 123, p. 126193, Feb. 2021, doi: 10.1016/j.eja.2020.126193.
- [56] Z. Zhou, Y. Majeed, G. Diverres Naranjo, and E. M. T. Gambacorta, “Assessment for crop water stress with infrared thermal imagery in precision agriculture: A review and future prospects for deep learning

- applications,” *Comput. Electron. Agric.*, vol. 182, p. 106019, Mar. 2021, doi: 10.1016/j.compag.2021.106019.
- [57] S. Liu *et al.*, “Diagnosis of nitrogen status in winter oilseed rape (*Brassica napus* L.) using in-situ hyperspectral data and unmanned aerial vehicle (UAV) multispectral images,” *Comput. Electron. Agric.*, vol. 151, no. May, pp. 185–195, 2018, doi: 10.1016/j.compag.2018.05.026.
- [58] L. Wan *et al.*, “Grain yield prediction of rice using multi-temporal UAV-based RGB and multispectral images and model transfer – a case study of small farmlands in the South of China,” *Agric. For. Meteorol.*, vol. 291, p. 108096, Sep. 2020, doi: 10.1016/j.agrformet.2020.108096.
- [59] P. R. Mwinuka, B. P. Mbilinyi, W. B. Mbungu, S. K. Mourice, H. F. Mahoo, and P. Schmitter, “The feasibility of hand-held thermal and UAV-based multispectral imaging for canopy water status assessment and yield prediction of irrigated African eggplant (*Solanum aethopicum* L.),” *Agric. Water Manag.*, vol. 245, p. 106584, Feb. 2021, doi: 10.1016/j.agwat.2020.106584.
- [60] V. de J. M. Bianchini *et al.*, “Multispectral and X-ray images for characterization of *Jatropha curcas* L. seed quality,” *Plant Methods*, vol. 17, no. 1, p. 9, Dec. 2021, doi: 10.1186/s13007-021-00709-6.
- [61] A. K. Chandel, L. R. Khot, C. O. Stockle, R. T. Peters, and S. Mantle, “Spatiotemporal water use mapping of a commercial apple orchard using UAS based spectral imagery,” *2020 IEEE Int. Work. Metrol. Agric. For. MetroAgriFor 2020 - Proc.*, pp. 268–272, Nov. 2020, doi: 10.1109/MetroAgriFor50201.2020.9277550.
- [62] G. Sun, Y. Ding, X. Wang, W. Lu, Y. Sun, and H. Yu, “Nondestructive Determination of Nitrogen, Phosphorus and Potassium Contents in Greenhouse Tomato Plants Based on Multispectral Three-Dimensional Imaging,” *Sensors*, vol. 19, no. 23, p. 5295, Dec. 2019, doi: 10.3390/s19235295.
- [63] I. Torres, M. T. Sánchez, B. K. Cho, A. Garrido-Varo, and D. Pérez-Marín, “Setting up a methodology to distinguish between green oranges and leaves using hyperspectral imaging,” *Comput. Electron. Agric.*, vol. 167, p. 105070, Dec. 2019, doi: 10.1016/j.compag.2019.105070.
- [64] K. Velumani *et al.*, “An automatic method based on daily in situ images and deep learning to date wheat heading stage,” *F. Crop. Res.*, vol. 252, p. 107793, Jul. 2020, doi: 10.1016/j.fcr.2020.107793.
- [65] A. López, J. M. Jurado, C. J. Ogayar, and F. R. Feito, “A framework for registering UAV-based imagery for crop-tracking in Precision Agriculture,” *Int. J. Appl. Earth Obs. Geoinf.*, vol. 97, p. 102274, May 2021, doi: 10.1016/j.jag.2020.102274.
- [66] H. Zheng *et al.*, “Early season detection of rice plants using RGB, NIR-G-B and multispectral images from unmanned aerial vehicle (UAV),” *Comput. Electron. Agric.*, vol. 169, p. 105223, Feb. 2020, doi: 10.1016/j.compag.2020.105223.
- [67] Y. Shendryk, J. Sofonia, R. Garrard, Y. Rist, D. Skocaj, and P. Thorburn, “Fine-scale prediction of biomass and leaf nitrogen content in sugarcane using UAV LiDAR and multispectral imaging,” *Int. J. Appl. Earth Obs. Geoinf.*, vol. 92, p. 102177, Oct. 2020, doi: 10.1016/j.jag.2020.102177.
- [68] L. Wang, X. Zhou, X. Zhu, and W. Guo, “Estimation of leaf nitrogen concentration in wheat using the MK-SVR algorithm and satellite remote sensing data,” *Comput. Electron. Agric.*, vol. 140, pp. 327–337, Aug. 2017, doi: 10.1016/j.compag.2017.05.023.
- [69] P. Miphokasap and W. Wannasiri, “Estimations of Nitrogen Concentration in sugarcane using hyperspectral imagery,” *Sustain.*, vol. 10, no. 4, pp. 1–16, 2018, doi: 10.3390/su10041266.
- [70] J. Clevers, “An overview of crop nitrogen status assessment using hyperspectral remote sensing: Current status and perspectives,” *Eur. J. Agron.*, vol. 124, p. 126241, Mar. 2021, doi: 10.1016/j.eja.2021.126241.
- [71] G. Yang *et al.*, “Leaf nitrogen spectral reflectance model of winter wheat (*Triticum aestivum*) based on PROSPECT: simulation and inversion,” *J. Appl. Remote Sens.*, vol. 9, no. 1, p. 095976, 2015, doi: 10.1117/1.jrs.9.095976.
- [72] A. Llanderal *et al.*, “Approach to petiole sap nutritional diagnosis method by empirical model based on climatic and growth parameters,” *Agronomy*, vol. 10, no. 2, 2020, doi: 10.3390/agronomy10020188.
- [73] Z. Li *et al.*, “Remote Sensing of Leaf and Canopy Nitrogen Status in Winter Wheat (*Triticum aestivum* L.) Based on N-PROSAIL Model,” *Remote Sens.*, vol. 10, no. 9, p. 1463, Sep. 2018, doi: 10.3390/rs10091463.
- [74] L. E. Parent, D. E. Rozane, J. A. L. de Deus, and W. Natale, “Diagnosis of nutrient composition in fruit crops: Major developments,” in *Fruit Crops*, B. Saõ Paulo State University, UNESP, Registro, Ed. Québec, QC, Canada, 2020, pp. 145–156.
- [75] Z. Li *et al.*, “Multi-LUTs method for canopy nitrogen density estimation in winter wheat by field and UAV hyperspectral,” *Comput. Electron. Agric.*, vol. 162, pp. 174–182, Jul. 2019, doi: 10.1016/j.compag.2019.04.005.
- [76] F. M. Padilla, M. Farneselli, G. Gianquinto, F. Tei, and R. B. Thompson, “Monitoring nitrogen status of vegetable crops and soils for optimal nitrogen management,” *Agric. Water Manag.*, vol. 241, p. 106356, Nov. 2020, doi: 10.1016/j.agwat.2020.106356.
- [77] L. P. Osco *et al.*, “Improvement of leaf nitrogen content inference in Valencia-orange trees applying spectral analysis algorithms in UAV mounted-sensor images,” *Int. J. Appl. Earth Obs. Geoinf.*, vol. 83, p. 101907, Nov. 2019, doi: 10.1016/j.jag.2019.101907.
- [78] J. G. Kljusurić, T. Jurina, D. Valinger, M. Benkovi, and

- A. J. Tušek, "NIR spectroscopy and management of bioactive components, antioxidant activity, and macronutrients in fruits," *Fruit Crop.*, pp. 95–109, 2020, doi: 10.1016/b978-0-12-818732-6.00008-3.
- [79] Y. Fu *et al.*, "Progress of hyperspectral data processing and modelling for cereal crop nitrogen monitoring," *Comput. Electron. Agric.*, vol. 172, no. March, p. 105321, 2020, doi: 10.1016/j.compag.2020.105321.
- [80] K. Berger *et al.*, "Crop nitrogen monitoring : Recent progress and principal developments in the context of imaging spectroscopy missions," *Remote Sens. Environ.*, vol. 242, no. December 2019, p. 111758, 2020, doi: 10.1016/j.rse.2020.111758.
- [81] A. Chlingaryan, S. Sukkarieh, and B. Whelan, "Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture," *Comput. Electron. Agric.*, vol. 151, pp. 61–69, Aug. 2018, doi: 10.1016/J.COMPAG.2018.05.012.
- [82] M. Zhang, J. Zhou, K. A. Sudduth, and N. R. Kitchen, "ScienceDirect Estimation of maize yield and effects of variable- rate nitrogen application using UAV-based RGB imagery," *Biosyst. Eng.*, vol. 189, pp. 24–35, 2019, doi: 10.1016/j.biosystemseng.2019.11.001.
- [83] L. Lin, Z. Gao, and X. Liu, "Estimation of soil total nitrogen using the synthetic color learning machine (SCLM) method and hyperspectral data," *Geoderma*, vol. 380, p. 114664, Dec. 2020, doi: 10.1016/j.geoderma.2020.114664.
- [84] K. Berger *et al.*, "Retrieval of aboveground crop nitrogen content with a hybrid machine learning method," *Int. J. Appl. Earth Obs. Geoinf.*, vol. 92, p. 102174, Oct. 2020, doi: 10.1016/j.jag.2020.102174.
- [85] T. Liu *et al.*, "Recent advances in convolutional neural networks," *Pattern Recognit.*, vol. 77, pp. 354–377, 2017, doi: 10.1016/j.patcog.2017.10.013.